

ME315 - Lab 02

Maria Luiza dos Santos de Queiroz - RA: 183314

Processamento de Bases de Dados em Lote

1. Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

Resposta: Tomando x = vôos com atraso na chegada superior a 10 minutos e n = número total de vôos, obtemos que o percentual de vôos atrasados na chegada será x/n .

2. Crie uma função chamada `getStats` que, para um conjunto de qualquer tamanho de dados provenientes de `flights.csv.zip`, execute as seguintes tarefas (usando apenas verbos do `dplyr`):
 - a. Filtre o conjunto de dados de forma que contenha apenas observações das seguintes Cias. Aéreas: AA, DL, UA e US;
 - b. Remova observações que tenham valores faltantes em campos de interesse;
 - c. Agrupe o conjunto de dados resultante de acordo com: dia, mês e cia. aérea;
 - d. Para cada grupo em b., determine as estatísticas suficientes apontadas no item 1. e os retorne como um objeto da classe `tibble`;
 - e. A função deve receber apenas dois argumentos:
 - i) `input`: o conjunto de dados (referente ao lote em questão);
 - ii) `pos`: argumento de posicionamento de ponteiro dentro da base de dados. Apesar de existir na função, este argumento não será empregado internamente. É importante observar que, sem a definição deste argumento, será impossível fazer a leitura por partes.

```
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

`filter`, `lag`

Os seguintes objetos são mascarados por 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
getStats <- function(input, pos){
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(AIRLINE),
           !is.na(DAY),
           !is.na(MONTH),
           !is.na(ARRIVAL_DELAY),
           !is.na(YEAR)) %>%
    group_by(DAY, MONTH, AIRLINE, YEAR) %>%
    summarise(
      n = n(),
      x = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}
```

3. Utilize alguma função `readr::read_***_chunked` para importar o arquivo `flights.csv.zip`.
 - a. Configure o tamanho do lote (chunk) para 100 mil registros;
 - b. Configure a função de callback para instanciar DataFrames aplicando a função `getStats` criada acima;
 - c. Configure o argumento `col_types` de forma que ele leia, diretamente do arquivo, apenas as colunas de interesse (veja nota de aula para identificar como realizar esta tarefa);

```
library(readr)
flights <- read_csv_chunked(
  'flights.csv.zip',
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = cols_only(
    YEAR = col_integer(),
    MONTH = col_integer(),
    DAY = col_integer(),
```

```

  AIRLINE = col_character(),
  ARRIVAL_DELAY = col_double()
)
)

```

4. Crie uma função chamada `computeStats` que:

- Combine as estatísticas suficientes para compor a métrica final de interesse (percentual de atraso por dia/mês/cia aérea);
- Retorne as informações em um `tibble` contendo apenas as seguintes colunas:
 - Cia: sigla da companhia aérea;
 - Data: data, no formato AAAA-MM-DD (dica: utilize o comando `as.Date`);
 - Perc: percentual de atraso para aquela cia. aérea e data, apresentado como um número real no intervalo [0,1].

```

computeStats <- function(stats){
  stats %>%
    transmute(
      Cia = AIRLINE,
      Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-")),
      Perc = x/n
    ) %>%
    select(Cia, Data, Perc)
}

resultados <- computeStats(flights)
resultados

```

```

# A tibble: 1,478 x 3
  Cia    Data      Perc
  <chr> <date>    <dbl>
1 AA    2015-01-01 0.373
2 DL    2015-01-01 0.0847
3 UA    2015-01-01 0.289
4 US    2015-01-01 0.196
5 AA    2015-01-02 0.430
6 DL    2015-01-02 0.180
7 UA    2015-01-02 0.349
8 US    2015-01-02 0.195
9 AA    2015-01-03 0.538
10 DL   2015-01-03 0.347
# i 1,468 more rows

```

5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea.
- a. Instale e carregue os pacotes `ggcal` e `ggplot2`.

```
if (!require("remotes")) install.packages("remotes")
```

Carregando pacotes exigidos: remotes

```
remotes::install_github("jayjacobs/ggcal")
```

Skipping install of 'ggcal' from a github remote, the SHA1 (ab1a85ad) has not changed since 1
Use `force = TRUE` to force installation

```
library(ggcal)  
library(ggplot2)
```

- b. Defina uma paleta de cores em modo gradiente. Utilize o comando `scale_fill_gradient`. A cor inicial da paleta deve ser `#4575b4` e a cor final, `#d73027`. A paleta deve ser armazenada no objeto `pal`.

```
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")
```

- c. Crie uma função chamada `baseCalendario` que recebe 2 argumentos a seguir: `stats` (`tibble` com resultados calculados na questão 4) e `cia` (sigla da Cia. Aérea de interesse). A função deverá:
- i) Criar um subconjunto de `stats` de forma a conter informações de atraso e data apenas da Cia. Aérea dada por `cia`.
 - ii) Para o subconjunto acima, montar a base do calendário, utilizando `ggcal(x, y)`. Nesta notação, `x` representa as datas de interesse e `y`, os percentuais de atraso para as datas descritas em `x`.
 - iii) Retornar para o usuário a base do calendário criada acima.

```
baseCalendario <- function(stats, cia) {  
  sub <- stats %>%  
    filter(Cia == cia)  
  ggcal(sub$Data, sub$Perc)  
}
```


- d. Executar a função `baseCalendario` para cada uma das Cias. Aéreas e armazenar os resultados, respectivamente, nas variáveis: `cAA`, `cDL`, `cUA` e `cUS`.

```
cAA <- baseCalendario(resultados, "AA")
cDL <- baseCalendario(resultados, "DL")
cUA <- baseCalendario(resultados, "UA")
cUS <- baseCalendario(resultados, "US")
```

- e. Para cada uma das Cias. Aéreas, apresente o mapa de calor respectivo utilizando a combinação de camadas do `ggplot2`. Lembre-se de adicionar um título utilizando o comando `ggtitle`. Por exemplo, `cXX + pal + ggtitle("Titulo")`.


```
cAA + pal + ggtitle("Percentual de Atrasos - American Airlines (AA)")
```

Percentual de Atrasos – American Airlines (AA)




```
cDL + pal + ggtitle("Percentual de Atrasos - Delta Air Lines (DL)")
```

Percentual de Atrasos – Delta Air Lines (DL)




```
cUA + pal + ggtitle("Percentual de Atrasos – United Airlines (UA)")
```

Percentual de Atrasos – United Airlines (UA)



```
cUS + pal + ggtitle("Percentual de Atrasos - US Airways (US)")
```

Percentual de Atrasos – US Airways (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-25 09:56:02 -03"
```